# Reinforcement Learning Assignment 1 Report

姓名：王宸澤　　學號：B113040047　　系級：資訊工程學系 115 級

## 一、實驗設定

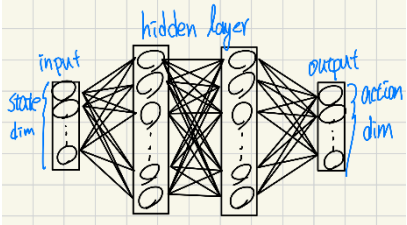


1. 介紹

   使用 DQN 解決 LunarLander-v3，其中 DQN 每層網路框架如右圖所示。

2. 參數

| | | | |
|---|---|---|---|
| Learning rate | $5*10^{-4}$ | Batch size | 64 |
| Discount factor | 0.99 | Replay buffer size | 10000 |
| Epsilon start | 1.0 | Target network update frequency | 10 |
| Epsilon end | 0.01 | Checkpoint frequency | 60 |
| Epsilon decay | 0.995 | Hidden layer dimension | 128 |
| Episodes | 600 | Neural network depth | 3 |

3. 實驗方式

   以上述參數的結果作為基準，調整某一參數，並執行兩次，結果取其平均，避免隨機值所產生的極端狀況發生。最後觀察其結果做出成因的推論。其中，相同變因，但變因數值不同的結果比較圖，會以 move average 20 來呈現，而圖中陰影部分為兩次實驗的平均取正負標準差後的範圍，若陰影部分較大，代表兩次結果相差較大。而實驗某變因的某數值，則以四種圖呈現原始數值及 move average 20 於圖中。

## 二、實驗過程與結果

### 實驗一：測試 Neural Network 的廣度與深度

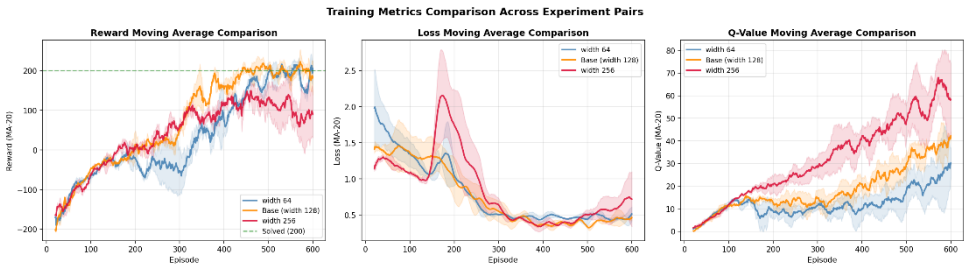


▲Neural network width 之 move average 比較圖

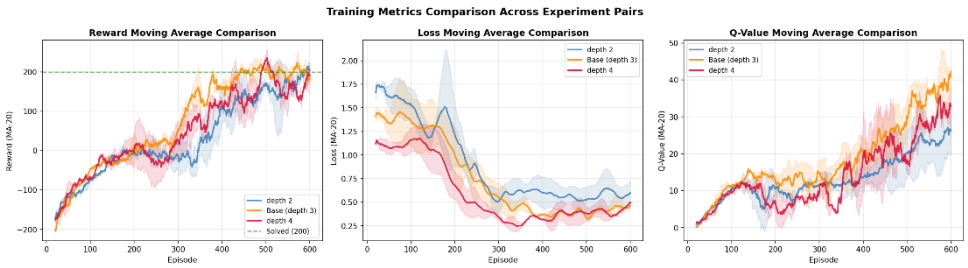


▲Neural network depth 之 move average 比較圖

發現除了 Q-value 外，訓練到最後，reward 與 loss 的結果都沒有太大的差異，因為此環境複雜程度較低，讓網路在一定的資料量便能夠收斂到優秀的成果。而在 Q-value 有差異的狀況下，loss 與 reward 又能有類似的成效，是因為 action 是以 argmax Q(s, a)選擇的，因此雖然平均的 Q-value 較低，但擁有相對最大值的 Q-value 仍是優秀的選擇。

不過值得注意的是，不論在深度或廣度增加與減少的狀況下，都讓訓練時間變長。在深度和廣度增加的情況下，因為需更新的參數較多，因此訓練時間會增長；而在深度和廣度減少的情況下，推測因為模型較不穩定（如圖中約在 episode 200 時，loss 急遽增加），使他在一個 episode 花費更多的 steps 來完成。

**實驗二：測試更新 DQN 中的 target network 的頻率**

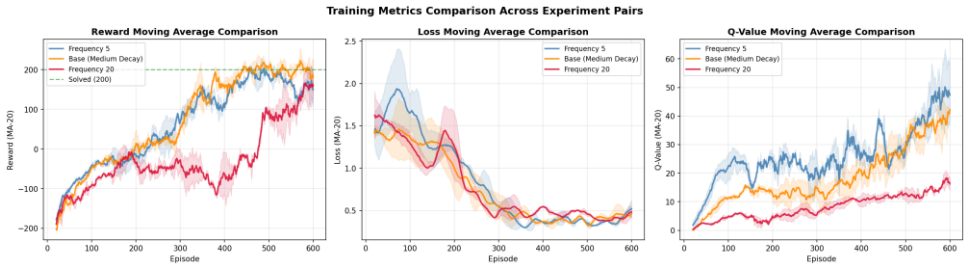


▲target network update frequency 之 move average 比較圖

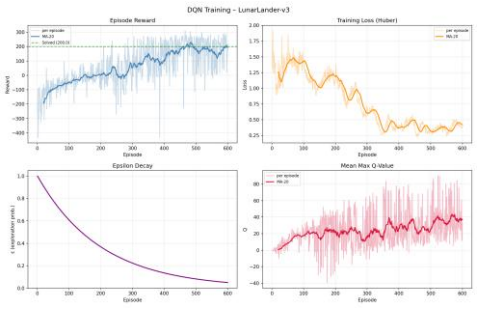


▲target network update per 5 episode

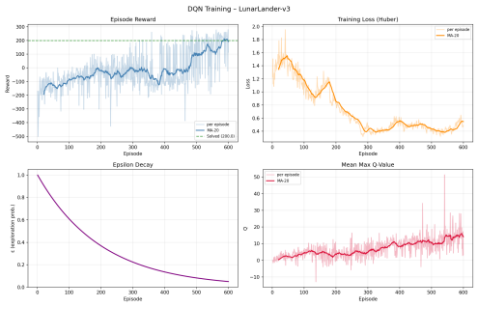


▲target network update per 20 episode

從上圖可見，更新頻率為 20 episodes 的情況下，其原始數值（下圖中顏色較淡的部分）相比更新頻率為 5 episodes 的情況更加穩定，但這反而使其較無機會探索到其他可能，導致在比較圖中，更新頻率為 20 的情況的成果較差。

**實驗三：測試 epsilon-greedy 的 Epsilon Decay 速度**

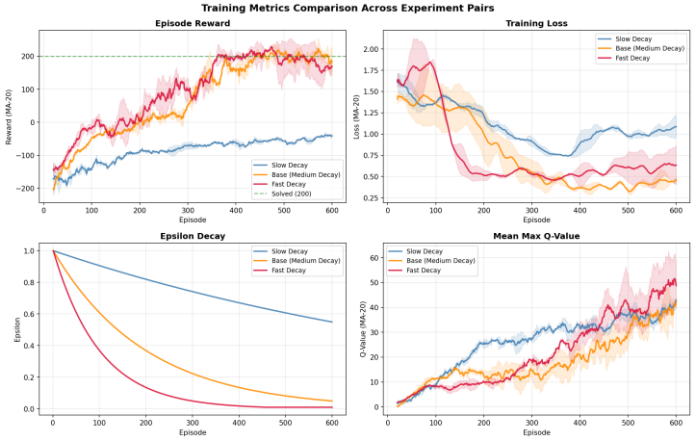


▲Epsilon Decay 之 move average 比較圖

Epsilon decay 代表每經過一個 episode，Epsilon 所衰減的比例，藉此讓模型進行 explore 的可能性隨著時間減少。從實驗結果可以發現，將 Epsilon decay 設為 0.99 時，在 500 episodes 之後，就幾乎不再 explore（即是 Epsilon 降至 Epsilon end），僅進行 exploit，而由於前面 500 episodes 已經藉由 explore 得到不錯的成效，因此模型在此之後，便能開始收斂，使其在 400 多 episode 就能解決問題。相反的 Epsilon decay 設為 0.999 時，根據計算，需到 4603 episodes 才會讓 epsilon 降到幾乎不會使模型進行 explore 的狀況，導致在 600 episodes 的訓練中，幾乎都處於 explore 的狀況，使其 reward 相當差。

## 三、結果討論

**改變幅度最明顯的 hyperparameter：epsilon decay**

將 epsilon decay 改為 0.99 後，發現收斂的速度更快，從 500 多 episodes 將問題解決，提早到 400 多 episodes。

**學習到的 Policy 與直覺上的登陸方式的差異**

直覺上，會認為登陸月球，應該要讓下方的主噴射器持續輸出，降低下降的速度，並讓左右兩側的噴射器依照狀況來控制角度，並在著陸後就停止。但模型學到的 Policy 為了增加獲得的 reward，會在一開始時使用側面噴射器來調整角度，並到了快著陸時，才用主噴射器降低速度。除此之外，若離登陸地太遠，還會持續使用側面噴射器，讓艙體移動到登陸地。